



TP – DATA EXPLORATION

1.Etude univariée.....	2
2.ACP.....	11
3.Etude bivariée.....	15
4.Clustering.....	19
5.Bonus.....	21

1. Etude univariée

L'objectif de cette première partie est de réaliser une étude descriptive univariée des variables contenues dans le jeu de données employes.

Cette étude vise à caractériser chaque variable prise individuellement, en identifiant sa nature (qualitative ou quantitative), en présentant un résumé numérique adapté, puis en proposant une représentation graphique pertinente.

Cette analyse permet de mieux comprendre la structure de la population étudiée avant d'aborder des analyses plus approfondies (bivariées ou multivariées).

1.1. Identifier le type de variables

Colonne	Nom (Code)	Type de Variable	Justification
ID	Identifiant	(hors analyse)	Simple étiquette unique pour l'individu. Aucune propriété statistique.
Salaire à l'Embauche	SALDEB	Quantitative (Continue)	Analyse à l'aide des indicateurs de position et de dispersion. Représentation par histogramme et boxplot.
Âge	AGE	Quantitative (Continue)	Analyse à l'aide du résumé numérique (min, quartiles, médiane, moyenne, max, écart-type). Représentation par histogramme et boxplot.
Ancienneté	ANC	Quantitative (Continue)	Analyse à l'aide des indicateurs de position et de dispersion. Représentation par histogramme et boxplot.
Salaire Actuel	SALACT	Quantitative (Continue)	Analyse à l'aide du résumé numérique (moyenne, médiane, quartiles, écart-type). Représentation par histogramme et boxplot.
Expérience	EXP	Quantitative (Continue)	Analyse par indicateurs de position et de dispersion. Représentation graphique par histogramme et boxplot.
Sexe	SEX	Qualitative (Nominale)	Variable qualitative nominale codée (0/1). Analyse à l'aide des effectifs et des fréquences. Représentation par diagramme en barres.
Niveau d'Études	NIVED	Quantitative (Discrète)	Analyse à l'aide du minimum, des quartiles, de la médiane, de la moyenne et du maximum, avec une représentation par diagramme en barres.
Catégorie de Métier	CATEG	Qualitative (Ordinale)	Analyse à l'aide des effectifs et des fréquences par catégorie. Représentation par diagramme en barres ordonné.

1.2. Analyse de chaque variable

1.2.1. Analyse du Salaire d'Embauche (SALDEB)

Type de variable : Quantitative Continue. Unités : unités monétaires


a) Résumé Numérique

Le tableau ci-dessous présente les indicateurs de tendance centrale et de dispersion calculés :


Indicateur	Valeur
Moyenne	6 806
Médiane	6 000
Écart-type	3 148
Minimum	3 600
Maximum	31 992
1er Quartile (Q1)	4 995
3ème Quartile (Q3)	6 996

b) Représentation Graphique

Histogramme du salaire à l'embauche



Boxplot du salaire à l'embauche



c) Analyse et Interprétation

L'analyse conjointe des indicateurs numériques et des graphiques révèle trois caractéristiques majeures de la politique d'embauche de l'entreprise :

- 1. Une distribution asymétrique à droite** (Skewness positive) : La moyenne (6 806) est sensiblement supérieure à la médiane (6 000). L'histogramme confirme cette asymétrie avec une "queue" de distribution qui s'étire vers les valeurs élevées. Cela signifie que la majorité des employés sont embauchés à un salaire relativement bas, tandis que la moyenne est tirée vers le haut par une minorité de salaires élevés.
- 2. Une forte concentration de la base salariale** : L'écart interquartile est faible (environ 2 000). 50% des employés ont débuté avec un salaire compris entre 4 995 et 6 996. Cela indique une homogénéité des salaires d'entrée pour la grande majorité du personnel (probablement les catégories ouvriers/employés).
- 3. La présence de valeurs aberrantes** (Outliers) : Le boxplot met en évidence des valeurs extrêmes situées bien au-delà de la moustache supérieure. Le salaire maximum (31 992) est près de 5 fois supérieur à la moyenne. Ces individus correspondent à des profils spécifiques (cadres dirigeants ou experts) dont les conditions d'embauche se détachent totalement du reste de la population.

Conclusion partielle : Dès l'embauche, une forte hiérarchie est établie avec une disparité importante entre la "masse" des salariés et quelques profils d'élite.

1.2.2. Analyse du Salaire Actuel (SALACT)

Type de variable : Quantitative Continue. Unités : unités monétaires


a) Résumé Numérique

Voici les statistiques descriptives observées pour la variable cible de notre étude :


Indicateur	Valeur
Moyenne	13 768
Médiane	
Écart-type	6 830
Minimum	6 300
Maximum	54 000
1er Quartile (Q1)	9 600
3ème Quartile (Q3)	14 775

b) Représentation Graphique

Histogramme du salaire actuel



Boxplot du salaire actuel



c) Analyse et Interprétation

La distribution du salaire actuel présente des caractéristiques encore plus marquées que celle du salaire d'embauche :

- Une dispersion très importante :** L'écart-type est de 6 830, ce qui est très élevé par rapport à la moyenne. L'étendue de la série (Max - Min) est de 47 700. Cela traduit de très fortes inégalités salariales au sein de l'entreprise.
- Une asymétrie positive accentuée :** La différence entre la moyenne (13 768) et la médiane (11 550) s'est creusée par rapport à l'embauche. Cela signifie que les augmentations de salaire n'ont pas été uniformes : une minorité d'employés a vu son salaire croître bien plus vite que la majorité, étirant la distribution vers la droite.
- Des valeurs aberrantes (Outliers) massives :** Le boxplot révèle des points atypiques très éloignés. Le salaire maximum (54 000) est presque 5 fois supérieur à la médiane. Ces valeurs correspondent vraisemblablement aux cadres supérieurs ou à la direction, dont la dynamique de rémunération est décorrélée du reste des employés.

1.2.3. Analyse de l'Âge (AGE)

Type de variable : Quantitative Continue. Unités : années.


a) Résumé Numérique

Le tableau ci-dessous présente les statistiques descriptives de la structure démographique de l'entreprise :


Indicateur	Valeur
Moyenne	37.2
Médiane	32
Écart-type	11.8
Minimum	23
Maximum	64.5
1er Quartile (Q1)	28.5
3ème Quartile (Q3)	45.98

b) Représentation Graphique

Histogramme de l'âge des salariés



Boxplot de l'âge



c) Analyse et Interprétation

L'étude de la variable AGE met en lumière la pyramide des âges de l'entreprise :

- Une population globalement jeune (Asymétrie Positive) :** La **Médiane (32 ans)** est nettement inférieure à la **Moyenne (37.2 ans)**.
→ Interprétation : 50% des effectifs ont moins de 32 ans. L'histogramme présente une asymétrie avec un pic de fréquence chez les jeunes employés (25-30 ans) et une décroissance progressive vers les âges plus élevés. La moyenne est tirée vers le haut par les employés seniors, moins nombreux.
- Une forte hétérogénéité générationnelle :** L'écart-type est élevé (près de 12 ans) et l'étendue couvre toute la vie active (de 23 à 64.5 ans).
→ Interprétation : L'entreprise n'est pas composée d'une seule classe d'âge. Elle mélange des jeunes diplômés (Q1 = 28.5 ans) et des salariés en fin de carrière, ce qui suggère une cohabitation entre juniors et seniors.
- Absence de valeurs atypiques (Outliers) :** Contrairement aux salaires, le boxplot de l'âge ne montre généralement pas de points extérieurs (ou très peu).
→ Interprétation : La distribution des âges reste dans des bornes biologiques et légales standards (pas d'employé de 12 ans ou de 90 ans). La distribution est plus régulière que celle des revenus.

Conclusion pour l'âge : L'entreprise semble être en phase de renouvellement ou de croissance, s'appuyant majoritairement sur une force de travail jeune (moins de 35 ans), encadrée par des seniors plus expérimentés.

1.2.4. Analyse de l'Expérience professionnelle (EXP)


Type de variable : Quantitative Continue. Unités : années.

a) Résumé Numérique

Ce tableau synthétise le bagage professionnel des salariés (expérience cumulée avant ou hors de l'entreprise) :

Indicateur	Valeur
Moyenne	7.99
Médiane	4.58
Écart-type	8.72
Minimum	0
Maximum	39.67
1er Quartile (Q1)	1.60
3ème Quartile (Q3)	11.56

b) Représentation Graphique



c) Analyse et Interprétation

La distribution de l'expérience est radicalement différente de celle de l'âge ou de l'ancienneté. Elle présente trois caractéristiques marquantes :

- 1. Une asymétrie positive extrême** : La Moyenne (8.0) est près du double de la Médiane (4.6).
 → Interprétation : La majorité des employés sont des profils "Juniors". Le 1er quartile (1.6 an) indique que **25% des salariés sont quasiment débutants** (moins d'un an et demi d'expérience). L'histogramme présente un pic très élevé à gauche (proche de 0) et décroît rapidement.
- 2. Une hétérogénéité maximale** : Fait rare en statistiques, l'Écart-type (8.7) est supérieur à la Moyenne (8.0).
 → Interprétation : La population n'est pas du tout homogène. Il n'y a pas de "profil type" d'expérience. L'entreprise fait cohabiter deux populations distinctes : une masse de jeunes débutants et un groupe restreint d'experts très qualifiés.
- 3. Des profils "Experts" isolés (Outliers)** : Le maximum est de presque 40 ans d'expérience.
 → Interprétation : Le boxplot mettra en évidence de nombreux points atypiques vers le haut. Ces individus correspondent vraisemblablement aux cadres dirigeants (ceux qui ont les salaires SALACT les plus élevés), recrutés pour leur expertise spécifique, contrairement à la masse salariale recrutée à la sortie de l'école.

Conclusion pour l'expérience : L'entreprise semble privilégier le recrutement de profils juniors peu expérimentés (probablement pour limiter la masse salariale), tout en s'appuyant sur quelques experts chevronnés.

1.2.5. Analyse de l'Ancienneté (ANC)


Type de variable : Quantitative Continue. Unités : mois.

a) Résumé Numérique

Les statistiques descriptives concernant la fidélité des employés à l'entreprise sont les suivantes :

Indicateur	Valeur
Moyenne	81
Médiane	81.11
Écart-type	10.06
Minimum	63
Maximum	98
1er Quartile (Q1)	72
3ème Quartile (Q3)	90

b) Représentation Graphique



c) Analyse et Interprétation

L'analyse de l'ancienneté révèle une structure très particulière, distincte des autres variables temporelles (Age, Expérience) :

1. **Une symétrie parfaite (Distribution Normale) :** Fait remarquable, la **Moyenne** (81.1) est quasiment identique à la **Médiane** (81.0).
→ Interprétation : Contrairement aux salaires ou à l'expérience qui sont asymétriques, l'ancienneté suit une distribution en cloche (Loi Normale ou Gaussienne). Il y a autant de personnes ayant une ancienneté inférieure à la moyenne que supérieure.
2. **Une population "établie" (Pas de nouveaux entrants) :** Le minimum observé est de 63 mois (soit plus de 5 ans).
→ Interprétation : Le jeu de données ne contient aucun nouvel embauché. Le salarié le plus récent est présent depuis plus de 5 ans. Cela suggère soit un gel des embauches depuis 5 ans, soit que l'échantillon a été filtré pour ne garder que les employés confirmés.
3. **Une forte homogénéité :** L'étendue est faible (Max - Min = 35 mois, soit moins de 3 ans d'écart entre le plus ancien et le plus récent). L'écart-type est faible (10 mois).
→ Interprétation : Toute la population étudiée a été recrutée dans une fenêtre de temps très courte (sur une période de 3 ans, il y a environ 6 à 8 ans). C'est une cohorte très homogène en termes de présence dans l'entreprise.

Conclusion pour l'ancienneté : Nous sommes face à une population stable, sans turn-over récent, recrutée massivement sur une courte période passée.

1.2.6. Analyse du Niveau d'Étude (NIVED)


Type de variable : Quantitative Discrète. Unités : années.

a) Résumé Numérique

Voici les statistiques descriptives concernant la scolarité des employés :

Indicateur	Valeur
Moyenne	13.49
Médiane	12
Écart-type	2.88
Minimum	8
Maximum	21
1er Quartile (Q1)	12
3ème Quartile (Q3)	15

b) Représentation Graphique



c) Analyse et Interprétation

La distribution du niveau d'études présente les caractéristiques suivantes :

- Une structure par paliers (Diplômes) :** Contrairement aux autres variables quantitatives, NIVED ne prend que quelques valeurs distinctes (principalement 8, 12, 15, 16).
 - Le Pic à 12 ans (Le Mode) :** La valeur la plus fréquente est 12 années, ce qui correspond généralement à la fin du cycle secondaire (Niveau Baccalauréat). Cela représente le "cœur" de l'effectif administratif.
 - Le seuil bas (8 ans) :** Le minimum est de 8 ans (fin de scolarité obligatoire de l'époque), correspondant probablement aux postes d'ouvriers ou d'employés non qualifiés.
 - Le seuil haut (15-16 ans et +) :** On observe un groupe important autour de 15-16 ans d'études (Niveau Licence/Master), correspondant aux cadres.

- Moyenne vs Médiane :** La Moyenne (13.5) est supérieure à la Médiane (12.0).

→ Interprétation : La population est tirée vers le haut par les diplômés du supérieur. Bien que 50% des employés aient un niveau inférieur ou égal au Bac (12 ans), le poids des cadres ayant fait de longues études (jusqu'à 21 ans, soit un Doctorat) augmente la moyenne globale.

Conclusion pour le Niveau d'Études : Le capital humain de l'entreprise est polarisé. On distingue clairement deux groupes : les employés de niveau secondaire (Bac ou moins) et les cadres de niveau supérieur (Universitaire). Cette variable sera probablement très corrélée au salaire (SALACT) et à la catégorie (CATEG) dans l'analyse bivariable.

1.2.7. Analyse du sexe de l'employé (SEX)

Type de variable : Qualitative Nominale. Modalités : 2 valeurs codées (0 et 1).

a) Tableau de Fréquences

La répartition des effectifs selon le genre est la suivante :

Sexe (code)	Effectif	Fréquence (%)
0	258	54.43%
1	216	45.57%
Total	474	100.00%

b) Représentation Graphique



c) Analyse et Interprétation

L'analyse de la variable démographique SEX permet de constater :

- Un équilibre relatif (Parité) :** La population de l'entreprise est partagée de manière assez équilibrée. Le groupe majoritaire (Code 0) représente 54.4% des effectifs, contre 45.6% pour le groupe minoritaire (Code 1). Il n'y a pas de domination écrasante d'un genre sur l'autre en termes de volume global.
- Importance pour l'étude ultérieure :** Bien que l'effectif soit équilibré, la question centrale des étapes suivantes (Analyse Bivariée et ACP) sera de déterminer si cette parité se retrouve dans les salaires et dans les catégories hiérarchiques.
 - Hypothèse à vérifier : Est-ce que le groupe 0 (majoritaire en nombre) est aussi majoritaire dans les hauts salaires, ou observe-t-on une ségrégation ?

Note méthodologique : Bien que codée numériquement (0/1), cette variable ne possède pas d'ordre intrinsèque. La moyenne (0.45) n'a aucune signification statistique.

1.2.1 Analyse de la Catégorie de métier (CATEG)


Type de variable : Qualitative Ordinale. Modalités : 7 niveaux hiérarchiques (codes 1 à 7).

a) Tableau de Fréquences

La répartition des effectifs par niveau hiérarchique est la suivante :

Catégorie	Effectif	Fréquence (%)
1	227	47.90%
2	136	28.70%
3	27	5.70%
4	41	8.60%
5	32	6.80%
6	5	1.10%
7	6	1.30%
Total	474	100%

b) Représentation Graphique



c) Analyse et Interprétation

L'organisation de l'entreprise présente une structure pyramidale classique :

- Une base opérationnelle massive** : Les Catégories 1 et 2 regroupent à elles seules 76.6% des effectifs.
 - Interprétation : Plus des trois quarts des salariés occupent des postes de bas niveau hiérarchique (employés administratifs, ouvriers, agents de sécurité...). La catégorie 1 est la plus représentée (presque 1 employé sur 2).
- Une élite restreinte (Le sommet de la pyramide)** : Les catégories supérieures (6 et 7) sont marginales, ne représentant que 2.4% de la population (11 personnes au total).
 - Interprétation : L'accès aux postes de haute direction est très limité. Ces individus correspondent très probablement aux valeurs atypiques (outliers) détectées précédemment sur les salaires (SALACT > 40 000) et l'expérience.
- L'encadrement intermédiaire** : Les catégories 3, 4 et 5 constituent le "management intermédiaire", représentant environ 21% des effectifs.

Conclusion pour la Catégorie : Cette variable confirme la forte hiérarchisation de l'entreprise suggérée par les écarts de salaires. Elle sera déterminante pour colorier les individus sur les graphiques de l'ACP (Partie 4).

2. ACP (Analyse en Composantes Principales)

L'objectif de cette seconde partie est de synthétiser l'information contenue dans les variables quantitatives du jeu de données employés à l'aide d'une Analyse en Composantes Principales (ACP).

L'ACP permet de :

- réduire la dimension du jeu de données,
- analyser les corrélations entre variables quantitatives,
- identifier des profils d'individus,
- et donner une interprétation synthétique des structures sous-jacentes.

Les variables quantitatives actives utilisées sont :

SALDEB, SALACT, AGE, EXP et ANC.

Les variables qualitatives SEX et CATEG ainsi que la variable NIVED sont introduites comme variables supplémentaires, afin d'éclairer l'interprétation sans influencer la construction des axes.
Les données ont été centrées et réduites afin de rendre les variables comparables.


1. Analyse des graphiques

1.2.1. Valeurs propres)

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	1.95904276	32.650713	32.65071
comp 2	1.74526444	29.087741	61.73845
comp 3	1.01836913	16.972819	78.71127
comp 4	0.98535586	16.422598	95.13387
comp 5	0.19235366	3.205894	98.33976
comp 6	0.09961414	1.660236	100.00000

Les deux premières composantes expliquent à elles seules 61,8 % de l'inertie totale, ce qui constitue une part suffisante de l'information pour une analyse en dimension réduite.

1.2.2. Choix du nombre d'axes (Scree plot)




Le graphique des valeurs propres montre que les deux premières composantes expliquent respectivement 32,7 % et 29,1 % de l'inertie totale.

Ainsi, le plan factoriel (Dim 1, Dim 2) cumule 61,8 % de l'information, ce qui est suffisant pour une interprétation fiable.

La décroissance marquée après la deuxième composante justifie le choix de se limiter à l'analyse des deux premiers axes.

1.3. Analyse des corrélations entre variables



Corrélations fortes :

- **SALDEB** et **SALACT** sont proches et orientées dans la même direction → fortement corrélées positivement.

Les individus bien rémunérés à l'embauche ont tendance à avoir un salaire actuel élevé.

- **AGE** et **EXP** sont également très proches, quasi colinéaires → corrélation positive très forte.

Plus un individu est âgé, plus son expérience est élevée.

Oppositions structurantes :

- Le couple **SALDEB** / **SALACT** est opposé au couple **AGE** / **EXP** sur l'axe 1.

Cela révèle une opposition nette entre profils économiques et profils temporels :

- jeunes bien rémunérés vs profils plus âgés/expérimentés.

Rôles de l'ancienneté :

- **ANC** est proche de l'origine : faible contribution et faible corrélation avec les autres variables.

L'ancienneté dans l'entreprise ne joue pas un rôle structurant dans l'organisation des profils salariaux ou d'âge.

Variable supplémentaire : NIVÉD

- **NIVÉD** est orientée vers les salaires et corrélée positivement à **SALDEB** et **SALACT**.

Le niveau d'études influence positivement le niveau de rémunération, sans structurer fortement les axes.

Interprétation des axes factoriels :

- Axe 1 (32.7%) : axe de la rémunération et du capital scolaire.

Cet axe est principalement structuré par les variables **SALDEB**, **SALACT** et, dans une moindre mesure, **NIVÉD**. À droite : salariés bien payés. À gauche : salariés moins payés.


Il oppose des profils faiblement rémunérés à des profils fortement rémunérés, généralement associés à un niveau d'études plus élevé.

- Axe 2 (29.1%) : axe de l'âge et de l'expérience professionnelle

Cet axe est dominé par les variables **AGE** et **EXP**, fortement corrélées entre elles. En haut : salariés âgés / expérimentés. En bas : salariés jeunes / peu expérimentés

Il traduit un gradient allant de profils jeunes et peu expérimentés à des profils plus âgés et expérimentés.

1.4. Analyse des individus



Le nuage des individus projetés sur le plan factoriel (Dim 1, Dim 2) présente une forte concentration autour de l'origine, traduisant une majorité de profils proches de la moyenne sur l'ensemble des variables étudiées.


L'axe 1, associé aux variables de rémunération (SALDEB, SALACT), met en évidence une dispersion plus marquée vers la droite, correspondant à des salariés bénéficiant de niveaux de salaire plus élevés. À l'inverse, les individus situés à gauche de l'axe 1 présentent des profils de rémunération plus faibles.

L'axe 2, dominé par les variables AGE et EXP, distingue les salariés plus âgés et expérimentés (positions élevées sur l'axe) des salariés plus jeunes et moins expérimentés (positions basses). Quelques individus apparaissent éloignés du centre, traduisant des profils atypiques, caractérisés soit par une rémunération particulièrement élevée, soit par une expérience professionnelle importante. Toutefois, la majorité des observations restent regroupées autour de l'origine, indiquant une structure globale relativement homogène de la population étudiée.

Cette répartition des individus est cohérente avec les oppositions mises en évidence lors de l'analyse des variables, confirmant la pertinence du plan factoriel retenu.

1.5. Effet des variables qualitatives supplémentaires

Catégorie de métier (CATEG) :




Le graphique des individus représente la projection des salariés sur le plan factoriel (Dim 1, Dim 2), qui cumule 61,8 % de l'inertie totale.

Le nuage est fortement concentré autour de l'origine, ce qui traduit une majorité de profils proches de la moyenne. L'axe 1 met en évidence un gradient de rémunération, opposant des salariés faiblement rémunérés à des salariés mieux rémunérés, tandis que l'axe 2 distingue les individus selon l'âge et l'expérience professionnelle.

Quelques individus plus éloignés du centre correspondent à des profils atypiques, notamment en termes de salaire ou d'expérience. Les individus ne sont pas identifiés individuellement afin de préserver la lisibilité du graphique compte tenu du nombre d'observations.

Sexe (SEX) :



La projection des individus selon la variable qualitative SEX ne montre pas de séparation nette entre les deux groupes sur le plan factoriel (Dim 1, Dim 2).

Les distributions des individus de sexe 0 et de sexe 1 se recouvrent largement, indiquant une absence de structuration marquée du nuage par le sexe. Les points roses correspondent aux barycentres des modalités, indiquant la position moyenne de chaque groupe sur le plan factoriel. Ces barycentres sont proches de l'origine et peu éloignés l'un de l'autre.

Ainsi, la variable SEX n'apparaît pas comme un facteur discriminant majeur des profils salariaux, d'âge ou d'expérience mis en évidence par l'ACP.

L'Analyse en Composantes Principales réalisée sur le jeu de données employés a permis de synthétiser efficacement l'information contenue dans les variables quantitatives étudiées. Les deux premières composantes principales expliquent à elles seules 61,8 % de l'inertie totale, ce qui justifie l'interprétation du plan factoriel (Dim 1, Dim 2).

L'analyse des corrélations entre variables met en évidence deux dimensions structurantes :

- l'axe 1, principalement associé aux variables de rémunération (**SALDEB**, **SALACT**), et dans une moindre mesure au niveau d'études (**NIVED**),
- l'axe 2, dominé par les variables **AGE** et **EXP**, traduisant un gradient d'expérience professionnelle.

La projection des individus révèle une forte concentration autour de l'origine, indiquant une majorité de profils proches de la moyenne, ainsi que quelques profils atypiques correspondant à des salariés très bien rémunérés ou très expérimentés. Cette répartition est cohérente avec les oppositions observées entre variables.

L'étude des variables qualitatives supplémentaires montre que la catégorie de métier (**CATEG**) est partiellement structurée selon l'axe de rémunération, tandis que la variable **SEX** ne présente pas de pouvoir discriminant notable sur le plan factoriel.

3. Étude Bivariée

Cette partie vise à étudier les relations existantes entre deux variables pour comprendre les mécanismes sous-jacents aux données.

3.1 Croisement Quantitatif - Quantitatif (SALACT et SALDEB)


L'objectif est d'étudier la relation entre le salaire d'embauche et le salaire actuel afin de déterminer si la rémunération actuelle d'un salarié est principalement conditionnée par son niveau de salaire initial, ou si l'entreprise permet une forte mobilité salariale au cours du temps.

a) Outils statistiques utilisés

Pour analyser cette relation, nous utilisons :

- un **nuage de points** pour visualiser la forme du lien,
- le **coefficient de corrélation linéaire de Pearson** (r) pour mesurer l'intensité du lien,
- un **modèle de régression linéaire simple** pour quantifier la part de variabilité expliquée via le coefficient de détermination R^2 ,
- des **boxplots** pour détecter la présence éventuelle de valeurs aberrantes.

b) Analyse graphique et régression linéaire :



"Coefficient de corrélation r : 0.88"

Le nuage de points met en évidence une relation linéaire croissante très marquée entre le salaire d'embauche et le salaire actuel. Les points sont fortement regroupés autour de la droite de régression, indiquant une dépendance importante entre les deux variables.

Le coefficient de corrélation de Pearson est élevé :

- **$r = 0,88$** , ce qui traduit une **corrélation positive très forte**.


Le modèle de régression linéaire confirme cette observation :

- $R^2 = 0,77$, ce qui signifie que 77 % de la variabilité du salaire actuel est expliquée par le salaire d'embauche.

Ce résultat indique que le salaire initial joue un rôle déterminant dans la trajectoire salariale des individus. Les autres facteurs (ancienneté, performance, promotions, etc.) n'expliquent qu'environ 23 % de la variabilité restante.

On observe également une dispersion croissante pour les salaires élevés, traduisant une hétérogénéité plus forte des trajectoires salariales dans le haut de la distribution.

c) Analyse des boxplots et valeurs aberrantes



Les boxplots du salaire d'embauche et du salaire actuel mettent en évidence la présence de valeurs aberrantes, principalement situées dans la partie haute de la distribution.

Ces observations correspondent à des profils atypiques, caractérisés par des niveaux de rémunération particulièrement élevés. Elles peuvent influencer l'estimation du modèle de régression en accentuant la dispersion et en limitant la capacité explicative du modèle.

Dans une démarche d'analyse approfondie, il serait pertinent de :

- construire un modèle alternatif en excluant ces valeurs aberrantes,
- comparer les coefficients et le R^2 afin d'évaluer si la relation linéaire devient encore plus explicative.

L'objectif ne serait pas d'atteindre artificiellement un R^2 proche de 100 %, mais de vérifier la robustesse du lien observé en l'absence de profils extrêmes.

L'analyse met en évidence un lien linéaire très fort entre le salaire d'embauche et le salaire actuel.

Le coefficient de corrélation élevé ($r = 0,88$) et le coefficient de détermination ($R^2 = 0,77$) montrent que le salaire initial explique l'essentiel des écarts de salaires actuels.

Le nuage de points et la droite de régression confirment une hiérarchie salariale largement déterminée dès l'entrée dans l'entreprise. La mobilité salariale existe, mais elle reste fortement contrainte par le niveau de départ.

Les boxplots révèlent la présence de valeurs aberrantes, principalement pour les salaires élevés. Une analyse complémentaire pourrait consister à estimer un modèle sans ces valeurs afin de tester la robustesse du lien observé.

3.1 Croisement Quantitatif - Qualitatif

Pour cette seconde analyse, nous étudions l'impact du niveau hiérarchique sur la rémunération.

Variables choisies :

- Variable Quantitative : Salaire Actuel (SALACT)
- Variable Qualitative : Catégorie Professionnelle (CATEG)

Question :

Le salaire dépend-il de la catégorie professionnelle ?

a) Outils et Méthode

- Boxplots : `boxplot(SALACT ~ CATEG)`
- Modèle linéaire : `lm(SALACT ~ CATEG)`
- ANOVA : `anova(modele)`

a) Résultats statistiques :

- ANOVA : $F = 171.1$ et $p\text{-value} < 2e-16$


→ Le lien entre salaire et catégorie est hautement significatif.

```

      Df    Sum Sq   Mean Sq F value Pr(>F)
CATEG    6 1.517e+10  2.528e+09   171.1 <2e-16 ***
Residuals 467  6.899e+09  1.477e+07
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

b) Analyse graphique (boxplot)



Le graphique met en évidence une structure salariale très segmentée :

1. **Une hiérarchie en escalier** (Lien fort) : On observe une progression systématique : la médiane des salaires (le trait noir au milieu de chaque boîte) augmente à chaque passage de catégorie. Être dans une catégorie supérieure garantit quasi-systématiquement un salaire de base plus élevé.
2. **L'hétérogénéité des Cadres** (Disparités) :
 - **En bas de l'échelle** (Catégories 1, 2, 3) : Les boîtes sont "petites" et compactes. Cela signifie que les ouvriers et employés ont des salaires très proches les uns des autres. Il y a peu de disparités.
 - **En haut de l'échelle** (Catégories 6 et 7) : Les boîtes sont très allongées verticalement. Chez les directeurs (Catégorie 7), les écarts de salaires sont énormes entre les individus.


Réponse à la question : Oui, la catégorie détermine le niveau moyen de salaire (effet de grille). Cependant, la nature des inégalités change : les bas statuts ont des salaires homogènes, tandis que les hauts statuts subissent une forte variabilité individuelle (probablement liée à la performance ou à l'ancienneté spécifique).

4. Classification Automatique (Clustering)

Dans cette partie, nous cherchons à segmenter les employés en groupes homogènes (profils types) en utilisant les variables quantitatives actives : Salaire de début, Salaire actuel, Age, Expérience et Ancienneté.

Nous avons opté pour l'algorithme des K-Means (Centres Mobiles) sur les données centrées et réduites, méthode adaptée aux jeux de données de cette taille.

4.1. Justification du nombre de clusters




Le choix du nombre de classes (k) est une étape cruciale. Pour ce faire, nous avons utilisé la méthode de la part de variance expliquée (R^2). Nous cherchons le compromis idéal entre un nombre restreint de classes et une forte homogénéité au sein de ces classes.

Analyse : Nous observons une cassure nette de la courbe ("règle du coude") à $k=3$.

- Pour 3 classes, le modèle explique 54 % de l'inertie totale.
- Ajouter une 4ème classe n'apporte qu'un gain marginal de variance expliquée.
- Nous retenons donc une partition en **3 classes**.

4.2 Résultats graphique (Plan factoriel)

Pour visualiser la qualité de la partition, nous avons projeté les individus sur le premier plan factoriel de l'ACP (Axes 1 et 2), en coloriant les points selon leur groupe d'appartenance.



Le graphique montre trois nuages de points bien distincts, sans chevauchement significatif. Cela confirme que les groupes sont statistiquement cohérents et bien différenciés.

4.3. Interprétation des profils

L'analyse des centres de gravité des classes (moyennes des variables pour chaque groupe) nous permet d'identifier trois profils types de salariés :

- **Classe 1 :** "Les Cadres / Hauts Revenus" (Effectif minoritaire)

Ce groupe se distingue par des rémunérations très élevées (Salaire actuel moyen environ 28 015, contre moins de 13 000 pour les autres). Il s'agit de salariés d'âge moyen (36 ans), correspondant probablement à des postes de direction ou de cadres supérieurs.

- **Classe 2 :** "Les Seniors peu qualifiés"

Ce groupe rassemble les individus les plus âgés (moyenne de 53,6 ans) et les plus expérimentés (18 ans d'expérience préalable). Malgré cette ancienneté sur le marché du travail, ils perçoivent les salaires les plus bas de l'entreprise (environ 10 011). Cela suggère des employés ou ouvriers en fin de carrière dont le salaire a peu progressé.

- **Classe 3 :** "Les Juniors / Débutants"


Ce groupe est constitué des salariés les plus jeunes (29,6 ans) avec peu d'expérience préalable (3,5 ans). Leurs salaires sont intermédiaires (environ 12 214) et correspondent à une phase de début de carrière.

Note : L'ancienneté dans l'entreprise (ANC) est quasiment identique pour les trois groupes (environ 81 mois). Ce critère ne permet pas de différencier les employés.

5. Bonus : Approche comparative (CAH)


Afin de valider la robustesse de nos résultats, nous avons repris l'analyse avec un second algorithme vu en cours : la Classification Ascendante Hiérarchique (CAH), utilisant la distance euclidienne et le critère de Ward.

5.1. Analyse du Dendrogramme



L'observation de l'arbre de classification (dendrogramme) confirme notre choix précédent. La structure des données montre une séparation naturelle en 3 branches principales avant que les sauts d'inertie ne deviennent trop faibles.

5.2. Comparaison avec les K-Means



En projetant les résultats de la CAH sur le plan factoriel, nous retrouvons une structure quasi-identique à celle obtenue par les K-Means.

Conclusion : La typologie en 3 profils (Juniors, Seniors bas salaires, Cadres) est robuste et ne dépend pas de l'algorithme choisi.